Separation and imaging of diffractions using a dilated convolutional neural network

Sheng & Zhao (2022), *Geophysics*, 87(3), S117–S127

Matheus Augusto Monteiro da Silva
Raphael Ramos da Silva

PPGEEC2327 – IA aplicada à geofísica – Prof. Tiago Barros – UFRN

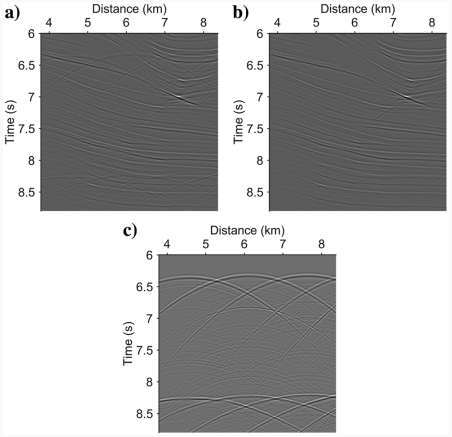
Motivação

- Difrações revelam estruturas **pequenas**: falhas, fraturas, cavidades.
- Reflexões, muito mais fortes, as **mascaram**.
- Métodos clássicos (ex.: PWD) exigem ajuste manual e falham com reflexões de **alto mergulho**.

Problema

$\mathbf{y} = \mathbf{d} + \mathbf{r}$ (dado = difração + reflexão)

Recuperar $\mathbf{d}$ a partir de $\mathbf{y}$.



(a) dado (b) só reflexão (c) só difração

Fonte: Sheng & Zhao (2022), Fig. 5

Visão geral



Aprendizado supervisionado:

$$\arg\min_{\theta} \left\| R(\mathbf{y}; \theta) - \mathbf{d} \right\|_F^2$$

R: saída da rede $\quad \theta = \{\mathbf{W}, \mathbf{b}\}$: pesos

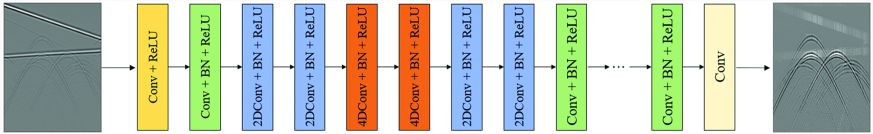
Metodologia

Aprendizado residual: alvo é a parte pequena, $\mathbf{d}$

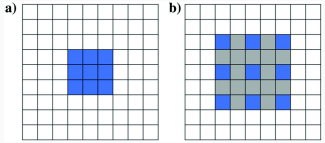
Convolução dilatada: janela maior

Batch normalization: treino mais rápido

Arquitetura e campo receptivo



Fonte: Sheng & Zhao (2022), Fig. 1



Fonte: Sheng & Zhao (2022), Fig. 2

- Conv 3×3, 64 filtros, BN + ReLU; camadas 3–8 **dilatadas**.
- Campo receptivo: **35** (CNN comum) $\rightarrow$ **55** (DCNN), sem pesos extras.

Ideia-chave

De perto, uma hipérbole parece reta; uma janela maior enxerga a **curvatura**.

Treinamento

- **Função de perda**: média das perdas no lote

$$l(\boldsymbol{\theta}) = \frac{1}{2N} \sum_{i=1}^{N} \left\| R(\mathbf{y}_i; \boldsymbol{\theta}) - \underbrace{(\mathbf{y}_i - \mathbf{r}_i)}_{\mathbf{d}_i} \right\|_F^2$$

- Otimizador **Adam** + cosine annealing com *warm restart*.
- Dados sintéticos: gabarito por subtração (modelo com − sem espalhadores).
- Recortes 55×55; lote 32; 60 épocas.
- Teste no **Sigsbee2A**, fora do treino.

Treinamento: cosine annealing

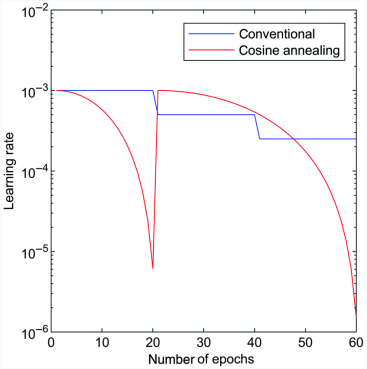
Taxa de aprendizado na época t:

$$\alpha_t = \alpha^j_{\text{min}} + \tfrac{1}{2}\left(\alpha^j_{\text{max}} - \alpha^j_{\text{min}}\right)\left(1 + \cos\left(\frac{T_{\text{cur}}}{T_j}\,\pi\right)\right)$$

j: j-ésimo reinício
α^j_{max}, α^j_{min}: taxas máxima e mínima
T_{cur}: épocas decorridas; T_j: época do reinício

Conventional* × *Annealing

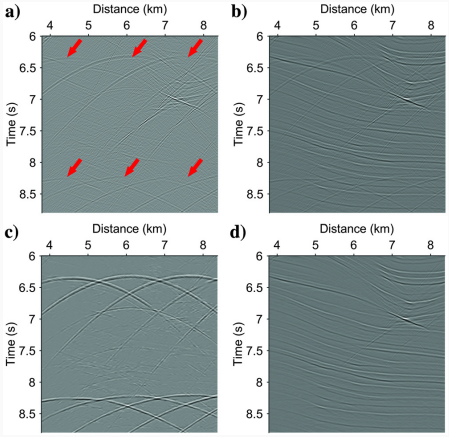
Conventional: taxa de aprendizado cai em "degraus"
Annealing: a taxa cai suavemente, em forma de cosseno, voltando a subir periodicamente (*warm restart*). Esse reinício ajuda a escapar de mínimos locais e "automatiza" a atualização de α.



taxa de aprendizado: degraus × cosseno

Fonte: Sheng & Zhao (2022), Fig. 3

Sigsbee2A: PWD × DCNN



(a) PWD (b) resíduo (c) DCNN (d) resíduo

Fonte: Sheng & Zhao (2022), Fig. 9

- PWD apaga os ápices e trechos tangentes (setas).
- DCNN preserva as hipérboles inteiras.

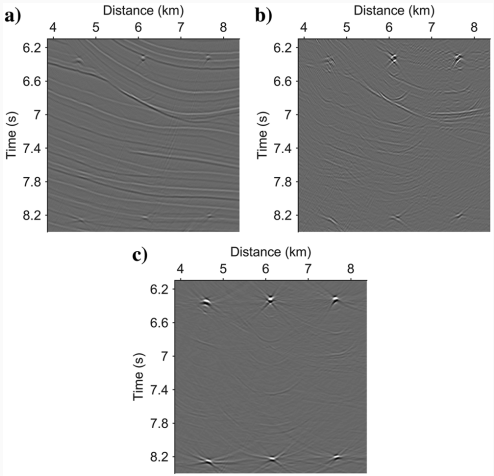
Método	EQM
PWD	$4{,}02 \times 10^{-4}$
CNN comum	$1{,}05 \times 10^{-4}$
DCNN	$\mathbf{3{,}59 \times 10^{-5}}$

EQM: erro quadrático médio

$\text{EQM} = \frac{1}{M} \sum_{k=1}^{M} \left(\hat{d}_k - d_k\right)^2$

Erro entre difração separada $\hat{\mathbf{d}}$ e verdadeira $\mathbf{d}$. Menor EQM = menos **energia perdida**.

Sigsbee2A: imagem de difração



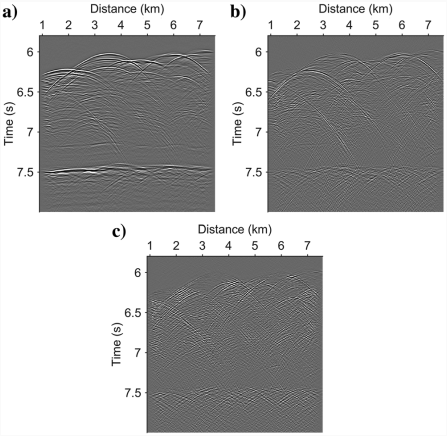
Fonte: Sheng & Zhao (2022), Fig. 10

(a) Migração convencional: espalhadores quase invisíveis.

(b) PWD: espalhadores borrados.

(c) DCNN: espalhadores **focalizados**.

Nankai: separação

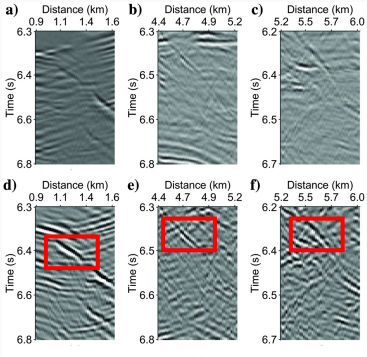


(a) dado (b) PWD (c) DCNN

Fonte: Sheng & Zhao (2022), Fig. 16

- Treino no **Viking Graben**, com rótulos gerados pelo PWD.
- Teste em Nankai: reflexões muito inclinadas.
- PWD deixa vazar reflexões; DCNN as remove melhor.

Nankai: imagem e limites



(a–c) migração convencional (d–f) imagem de difração

Fonte: Sheng & Zhao (2022), Fig. 18

- Fraturas pequenas ficam visíveis (retângulos).

Limite

Treinada só no sintético, a rede falha no campo: o treino precisa se parecer com o teste.

Obrigado!